

面向非结构化农业场景的机械臂具身 抓取研究--基于视觉语言模型(VLM) 与 ROS 2 的混合架构仿真验证

陆坚其 2453124
2026.5.14

A stylized, light gray illustration of a city skyline with various skyscrapers and buildings, serving as a background for the text.

01 研究背景与发展现状

02 系统总体架构

03 核心技术点

04 阶段性成果展示

05 存在的问题

06 未来规划

■ 研究背景：智慧农业



同濟大學

- 近年来，随着智慧农业向着自主化、智能化的方向发展，农业采摘机器人面临着在高度非结构化的农业场景下智能决策与自主作业的难题。

“精准感知-自主决策-智能控制-自动执行”的机器人是实现机械化作业的装备支撑

产业发展瓶颈：



机械化率低、人工成本高、效率低下

复杂作业要求：

- 目标识别感知
- 采摘任务决策
- 精准对靶控制
- 柔顺高效操作

复杂作业要求：智能农机



精准感知-自主决策-智能控制-自动执行

■ 发展现状

- 早期果蔬采摘机器人主要依赖传统目标检测与运动规划相结合的办法，已经实现了工程落地并投入实际生产中但也暴露出泛化能力弱，遮挡环境下采摘成功率大幅下降，且缺乏对障碍物物理属性的语义理解，无法区分可推挤的软质枝叶与必须绕行的刚性结构等痛点；
- 为解决复杂环境下的交互难题，近期的研究开始探索端到端的具身智能大模型。如RT-1,RT-2等端到端大模型展现出了极强的泛化能力，但VLA模型算力成本高、决策不可解释并且缺乏农业场景的数据集；
- 大模型感知结合传统运动控制的方式保留了VLM的语义理解优势，又保证了底层执行的安全性，但该架构在农业采摘垂直场景下尚缺乏针对性的仿真验证，尤其是 2D 语义决策到 3D 安全轨迹的映射精度问题尚未被系统评估。



图1 YOLO V8 双臂垄作草莓采摘机器人




图2 RT-2端到端大模型测试



深度感知

两台深度相机：Gemini335在外部获取全局俯视图像，ee_camera固定在夹爪上提供手眼近距离视角，二者构成全局粗定位 + 近距精定位的双阶段感知链路。




图1 Gazebo中两个相机的位置

智能决策

接入 Qwen-3.0-VL-Plus API，通过提示词约束VLM角色和任务，输入原始图像数据，获取JSON结构化输出，阶段一识别全局目标果实，阶段二精确定位果柄。

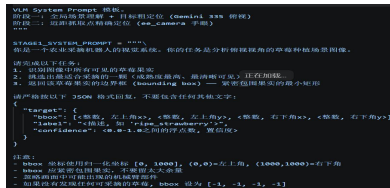


图2 VLM系统提示词

坐标转换

获取VLM输出的二维坐标数组，在区域内查询深度图的最小有效深度值，反投影到相机坐标系中，再经TF2 坐标变换至机械臂基坐标系。




图3 坐标转换过程

仿真

使用SO101机械臂，在Gazebo Classic 11中进行仿真，设计九阶状态机，整合MoveIt 2运动规划、Planning Scene 动态管理、Gazebo 物理引擎附着。




图4 Gazebo完整测试环境

核心技术点



同濟大學

双阶段VLM定位：

采取双阶段VLM定位策略，

阶段一：外部 Gemini 335 全局俯视图 → VLM 粗定位目标果实 bbox → 反投影得初始 3D 坐标 → 机械臂移动至预抓取位姿。阶段二：末端 ee_camera 手眼近距图 → VLM 精确定位果柄 → 修正抓取坐标。阶段二超时，降级使用阶段一坐标执行抓取。

2D-3D坐标转换：

VLM 输出目标边界框bbox，采用 Qwen3-VL 约定的 $[0,1000]$ 归一化坐标。将其转换为实际像素坐标后，在 bbox 区域内查询最小有效深度值，再进行坐标的转换，变换至机械臂坐标系。

基于 Python 构建多阶段有限状态机：将 VLM 感知到物体放置的全过程解耦为 SETUP → PRE_GRASP → APPROACH → GRASP → TRANSPORT → PLACE 等独立阶段。每个阶段只做一件事。




图1 系统整体架构图

■ 阶段性成果展示



同濟大學

成功搭建前期测试
场景与带遮挡随机
化草莓生成场景，
附上相机




图1 草莓随机生成场景

实现输出二维坐标
到三维坐标的准确
转换，VLM 坐标识
别准确率 $\geq 90\%$ ，
2D $\rightarrow$ 3D 转换定位
误 $\leq 10\text{mm}$

完成全链路代码编
写并成功跑通，API
调用成功率100%。

```
[vlm_bridge-13] [INFO] [1778789448.115243856] [vlm_bridge]: 收到任务指令: 抓取红色物体  
[vlm_bridge-13] [INFO] [1778789448.115764886] [vlm_bridge]: 触发推理-推理  
[vlm_bridge-13] [INFO] [1778789448.281694688] [vlm_bridge]: 阶段一-调用 VLM (Gemini335)...  
[vlm_bridge-13] [INFO] [1778789451.817763215] [vlm_bridge]: 阶段一结果: bbox_norm=[488, 642, 516, 686] + pixel=[212, 380, 310, 328]  
center=[212, 310] label=ridge_strawberry conf=0.95  
[vlm_bridge-13] [INFO] [1778789451.619279144] [vlm_bridge]: 阶段二-3D (base): (8.1558, -4.8889, 8.8488)  
[vlm_bridge-13] [INFO] [1778789451.181324533] [vlm_bridge]: 已发布: /target_are_grasp  
[grab_action-14] [INFO] [1778789451.184722163] [grab_action]: 收到预抓握目标: (8.156, -4.889, 8.848)  
[grab_action-14] [INFO] [1778789451.185128791] [grab_action]: SETUP: 注册目标物体到 Planning Scene...  
[grab_action-14] [INFO] [1778789451.186148138] [grab_action]: CollisionObject AD: target  
[grab_action-14] [INFO] [1778789451.188616616] [grab_action]: 目标物体已发布到 collision object  
[grab_action-14] [INFO] [1778789451.189634637] [grab_action]: 规划预抓握位置 (物体在 scene + MoveIt 运行)...
```

图2 全链路调用过程

全链路抓取已成功跑通，系统具备极强的落地可行性。

- 机械臂末端摄像机在预抓取位姿视角受限，难以拍摄到正下方的目标物体，导致 Stage 2 精定位阶段持续失败，实际抓取依赖 Stage 1 粗定位降级方案。
- ROS 2 Humble 不包含官方 moveit_py Python API，无法通过 ApplyPlanningScene 服务管理 PlanningScene。本课题改用 /collision_object 与 /attached_collision_object 话题直接发布的方式替代，实现了零阻塞的场景物体管理。
- 机械臂控制器配置为 open_loop_control: true，为开环控制，执行过程中缺少位置反馈校正。在部分预抓取位姿下，关节 4 超出 URDF 限位 0.1-0.15 rad，导致后续 Lift 阶段 MoveIt 拒绝规划。
- VLM 输出的二维坐标为物体顶部坐标，在转换时若物体的形状不同，转换精度会有所起伏，2D→3D 转换时需根据目标形状半高调整 Planning Scene。

- 利用 VLM 对场景物体进行语义分类，通过 Planning Scene Manager 的 `add_object` 与 `allow_collision` 接口差异化处理——树干保留为碰撞体，枝叶标记为可穿越，为机械臂推开软质障碍物提供语义依据。
- 扩展VLM的预设Prompt，让VLM从单目标输出到目标列表输出，新增多目标排序标签，`grab_action` 按优先级顺序执行多轮抓取。
- 设计设计无遮挡、单枝遮挡、多枝遮挡三类仿真场景，每组 10 次重复实验。对比开关语义排障模块的任务完成率与路径规划成功率，量化 VLM 语义决策对抓取性能的提升

谢谢！
